

# DEEP LEARNING WITH PYTORCH



# ABOUT AUTOGRAD

# ABOUT AUTOGRAD

---

## ◆ 인공신경망 (ANN : Artificial Neural Network)

### ❖ 동작원리

#### [ STEP1 ] 순전파 FORWARD PROPAGATION

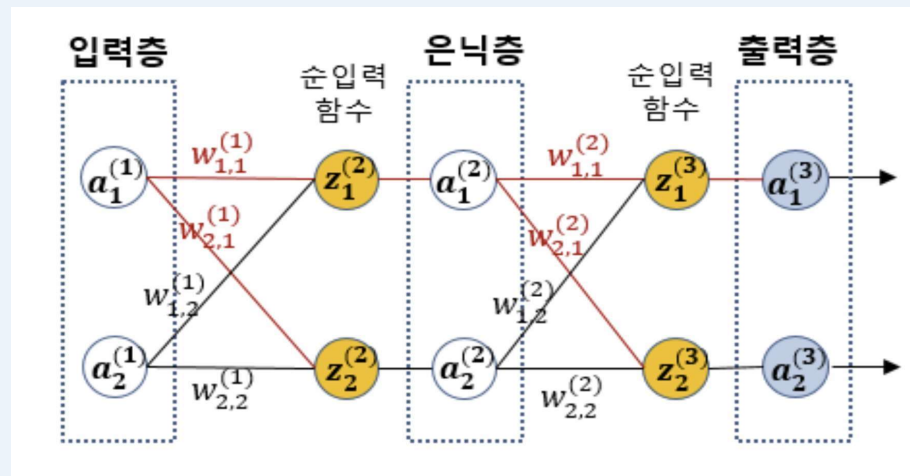
- 입력층 =====> 출력층 방향 계산 과정
- 신호와 가중치 곱한 값 출력층까지 차례대로 계산
- 피쳐1\*가중치1 + 피쳐2\*가중치2 + ..... + 피쳐n\*가중치n + b  
→ 활성화함수AF( 피쳐가중치합+b) → 결과값

# ABOUT AUTOGRAD

## ◆ 인공신경망 (ANN : Artificial Neural Network)

### ❖ 동작원리

#### [ STEP1 ] 순전파 FORWARD PROPAGATION



# ABOUT AUTOGRAD

---

## ◆ 인공신경망 (ANN : Artificial Neural Network)

### ❖ 동작원리

#### [ STEP2 ] 역전파 BACKWARD PROPAGATION


- 입력층 <==== 출력층 방향 계산 과정
- 오류에 대한 미분값, 학습률, 경사하강법 이용 최적화 값 입력층으로 전달
- 현재  $W, b$  - ((정답-예측값)의 미분값 \* 학습률)
  - ➔ 새로운  $W, b$  업데이트
  - ➔ 이전 층으로 전달

# ABOUT AUTOGRAD

## ◆ 인공신경망 (ANN : Artificial Neural Network)

### ❖ 동작원리

#### [ STEP2 ] 역전파 BACKWARD PROPAGATION




# ABOUT AUTOGRAD

## ◆ 인공신경망 (ANN : Artificial Neural Network)


### ❖ 동작원리

#### [ STEP2 ] 역전파 BACKWARD PROPAGATION



# ABOUT AUTOGRAD


## ◆ 인공신경망 (ANN : Artificial Neural Network)





# ABOUT AUTOGRAD

## ◆ 인공신경망 (ANN : Artificial Neural Network)



# ABOUT AUTOGRAD

---

## ◆ 오류역전파 알고리즘 (Backward Propagation)

- 1986년 제안된 효율적 최적화 알고리즘
- 경사하강법 이용 파라미터( $w, b$ ) 업데이트하며 학습 진행
- 각 Layer에서 손실함수 미분값 계산에 어려움을 해결한 알고리즘
- 미분학의 '체인룰' 착안 → 연쇄법칙
- 출력층에서 입력층로 오류를 전달하며 파라미터( $w, b$ ) 업데이트

# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화


### ❖ 잔차/오차와 가중치, 절편 관계

→ 잔차(Residual) : 표본 회귀식과 관측치 차이

→ 오차(Error) : 모집단의 회귀식과 관측치 차이

→ 최적화(Optimizer)

잔차/오차 최소화 하는 것



# ABOUT AUTOGRAD

---

## ◆ 가중치/절편 최적화

### ❖ 목적함수(Objective Function)

→ 최소화 또는 최대화 하고 싶어하는 함수

→ 최소화 함수

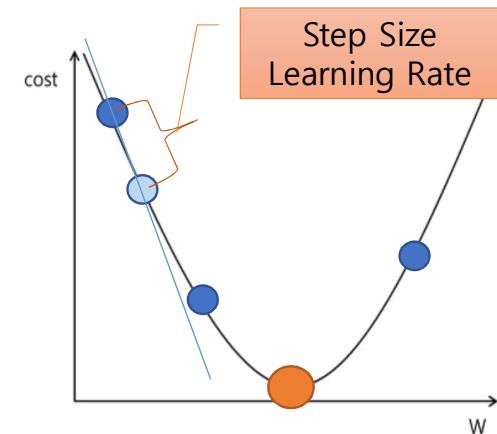
- 비용함수(cost function) : 전체 데이터 셋 대한 예측값과 실제값 차이 측정 함수
- 손실함수 (loss function) : 한 개 데이터 셋 대한 예측값과 실제값 차이 측정 함수
- 오류함수 (error function) : 딥러닝에서 손실 함수의 다른 말
- 최대화 함수
  - MLE, KL-Divergence

# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화

### ❖ 최적화 방법 - 경사하강법(Gradient Descent)

- 수학적 기법 중 하나
- 손실함수 값을 최소화하기 위해 기울기를 이용하는 사용
- **step-size** 간격으로 수행, 보통 0.1~0.001 속도가 적당
- 학습 데이터 수, 학습률에 따른 다양한 방법 존재




# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화

❖ 최적화 방법 - 경사하강법(Gradient Descent)

→ 새로운  $W, b$  계산 : 현재  $W$  - (오류/잔차/차이값 미분한 값 \* step-size)

→ 접선의 기울기 즉, 미분



# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화


### ❖ 최적화 방법 - 경사하강법(Gradient Descent)

- ① 처음 시작점(Initial starting point)은 랜덤으로 시작하여 시작점의 기울기,  $\nabla f(x)$  구하여 기울기의 경사정도(절대값)과 음 또는 양의 방향인지 확인
- ② Learning rate/step size라 불리는  $r$ 의 값을 임의적으로 수정하여 이동하고자 하는 거리만큼 점 이동
- ② 업데이트된 점에서 기울기를 구하여 0의 수렴하는지 확인
- ③ 기울기가 0의 수렴하지 않으면 1번으로 돌아가서 반복실행

# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화

❖ 최적화 방법 - 경사하강법(Gradient Descent)





# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화


### ❖ 최적화 방법 - 경사하강법(Gradient Descent)

#### Local Minimum

실제 최적화 지점이 아닌 지점  
최저점을 제외한 나머지 지점들

#### Global Minimum

최저점



# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화

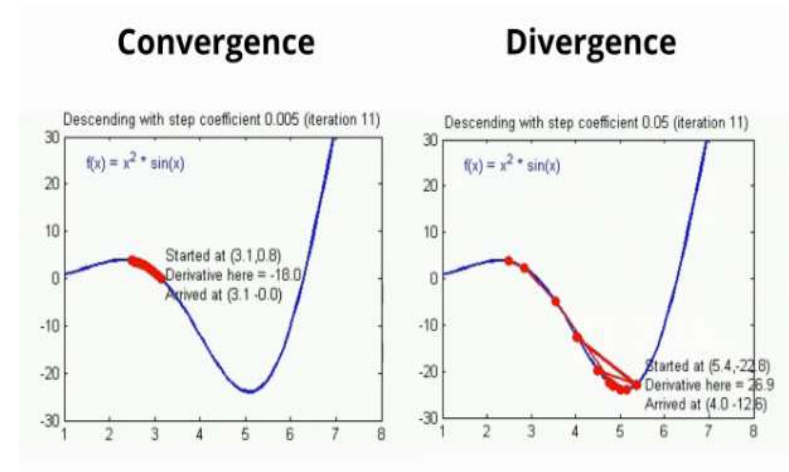
### ❖ 최적화 방법 - 경사하강법(Gradient Descent)

#### Local Minima Problem

Global minimum 아닌 Local minimum에서 멈추는 현상  
사실상 고차원공간에서 발생하기 힘든 현상

→ Momentum, Adagrad, Adam 등의 회피 최적화기법



→ Learning Rate 적절히 조절



# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화

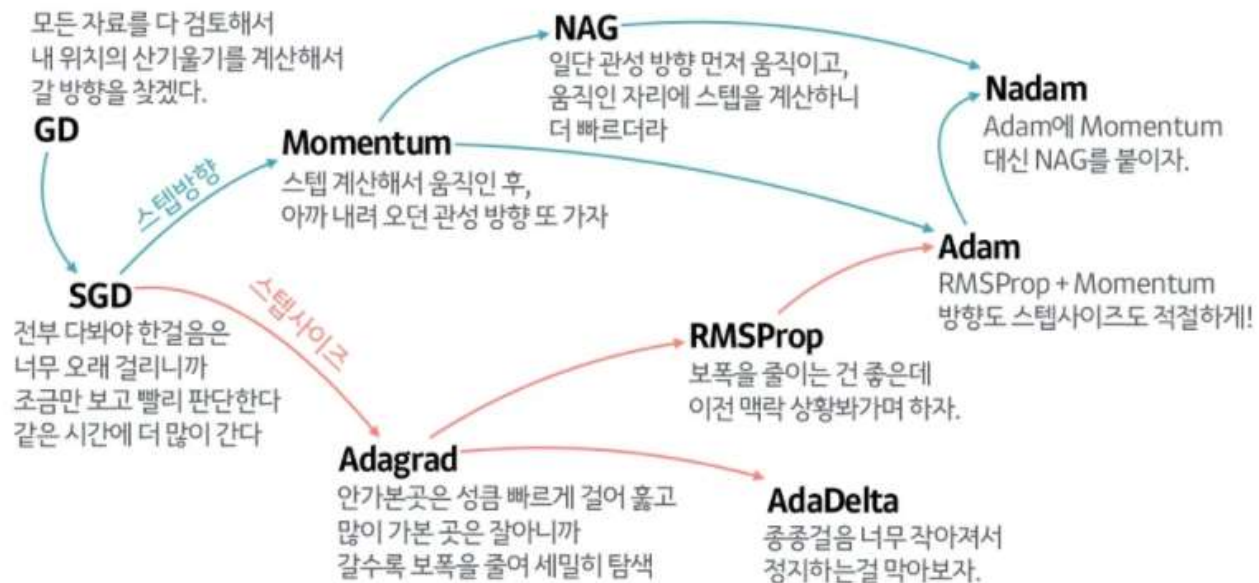
❖ 최적화 방법 - 경사하강법(Gradient Descent)



# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화

### ❖ 다양한 경사하강법



# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화

### ❖ 다양한 경사하강법(Gradient Descent)

Batch Gradient Descent	전체 데이터 학습 후 검증 및 업데이트 진행, 많은 시간 및 계산량 소요
SGD (Stochastic Gradient Descent)	일부 학습 데이터(mini-batch) 선택 후 진행 BGD에 비해 다소 부정확, 속도 빠름
Momentum	업데이트 시 이전 값과 비교하여 같은 방향으로 업데이트 진행 -> 관성
AdaGrad (Adaptive Gradient)	변수들 update 시 각각의 변수마다 lr 즉 step size 다르게 설정 갱신 정도 약해져 전혀 갱신되지 않는 경우 발생
RMSProp / AdaDelta	AdaGrad의 단점 보완, 과거 기울기는 조금 반영 + 최신 기울기 많이 반영
Adam (Adaptive Moment Estimation)	과거 미분값 계속 가중평균 내면서 효율적 업데이트 트 RMSProp + Momentum 방식 결합

# ABOUT AUTOGRAD

---

## ◆ torch.autograd

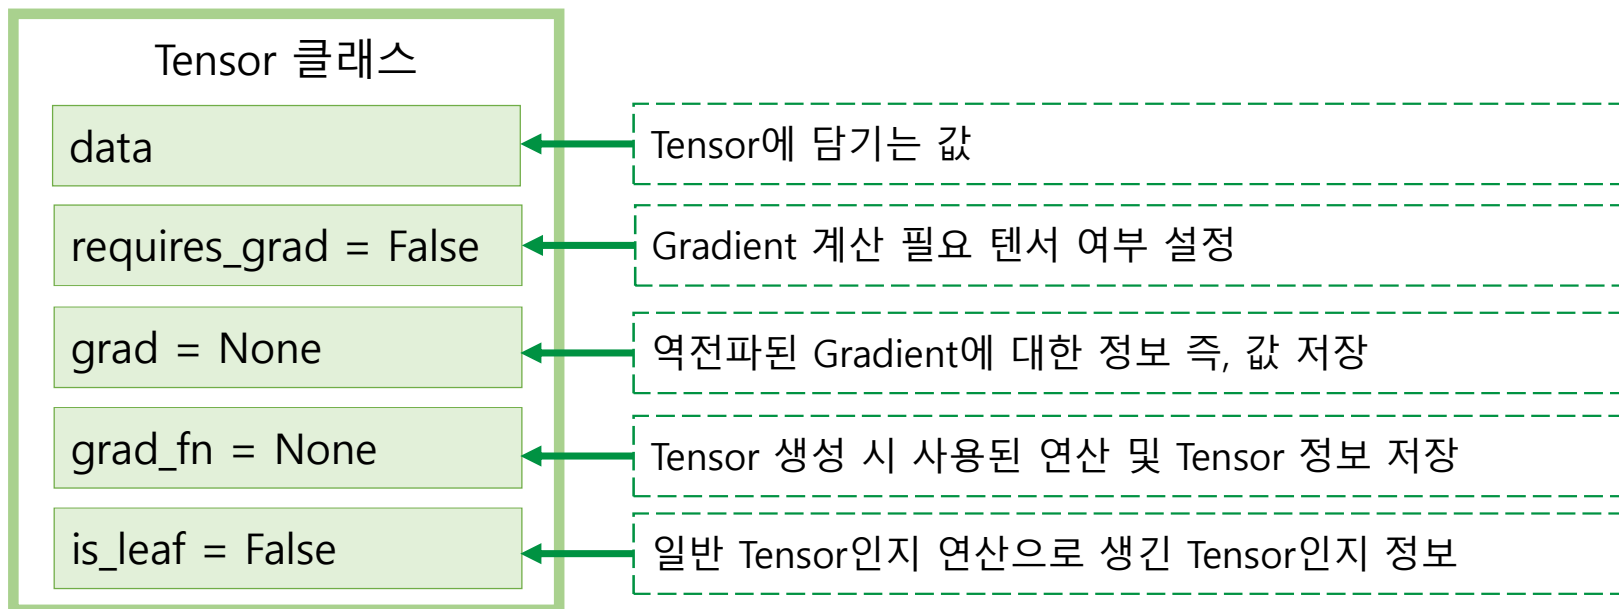
### ❖ 자동미분 기능

- 모델 복잡해질수록 **경사 하강법을 넘파이 등으로 직접 코딩하는 것은 까다로움**
- **파이토치**에서는 이런 수고를 하지 않도록 **자동 미분(Autograd)** 지원

# ABOUT AUTOGRAD

## ◆ torch.autograd

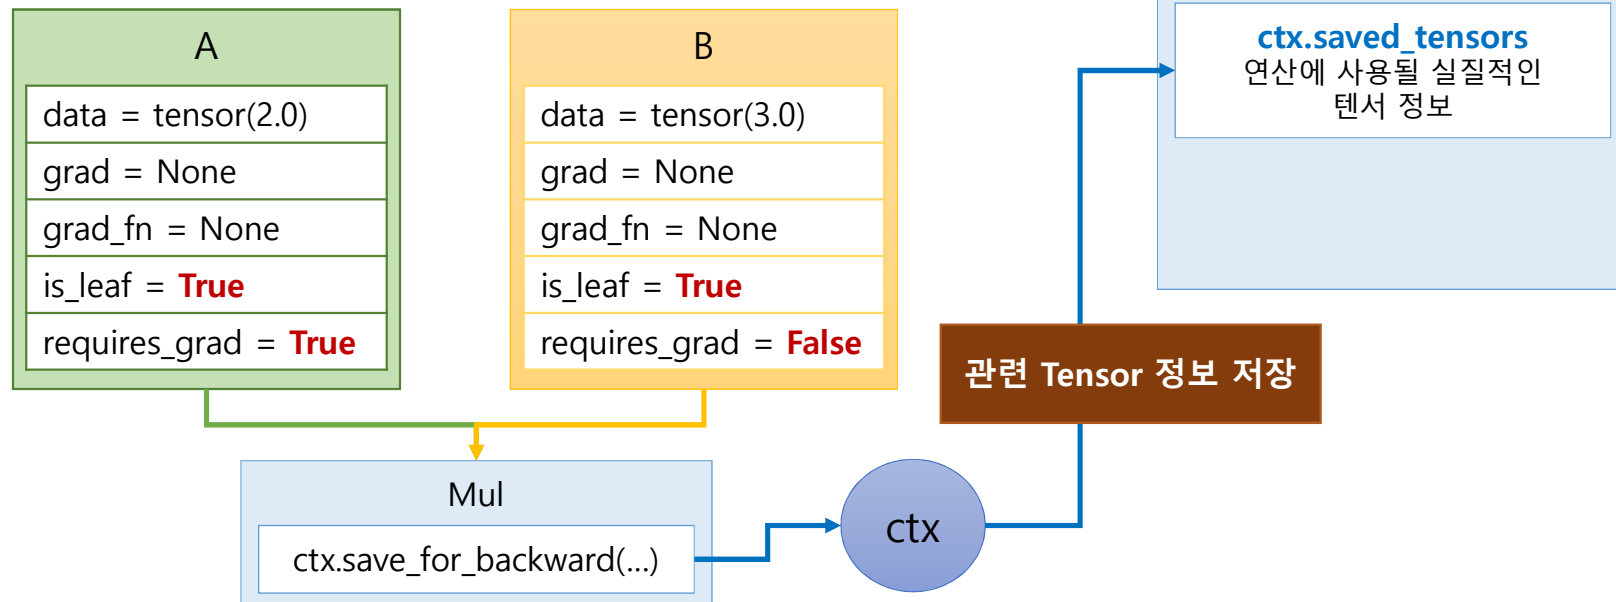
### ❖ 자동미분 관련 Tensor 속성



# ABOUT AUTOGRAD

## ◆ torch.autograd

❖ 동작원리 : Tensor 연산 진행 후 결과 Tensor 생성

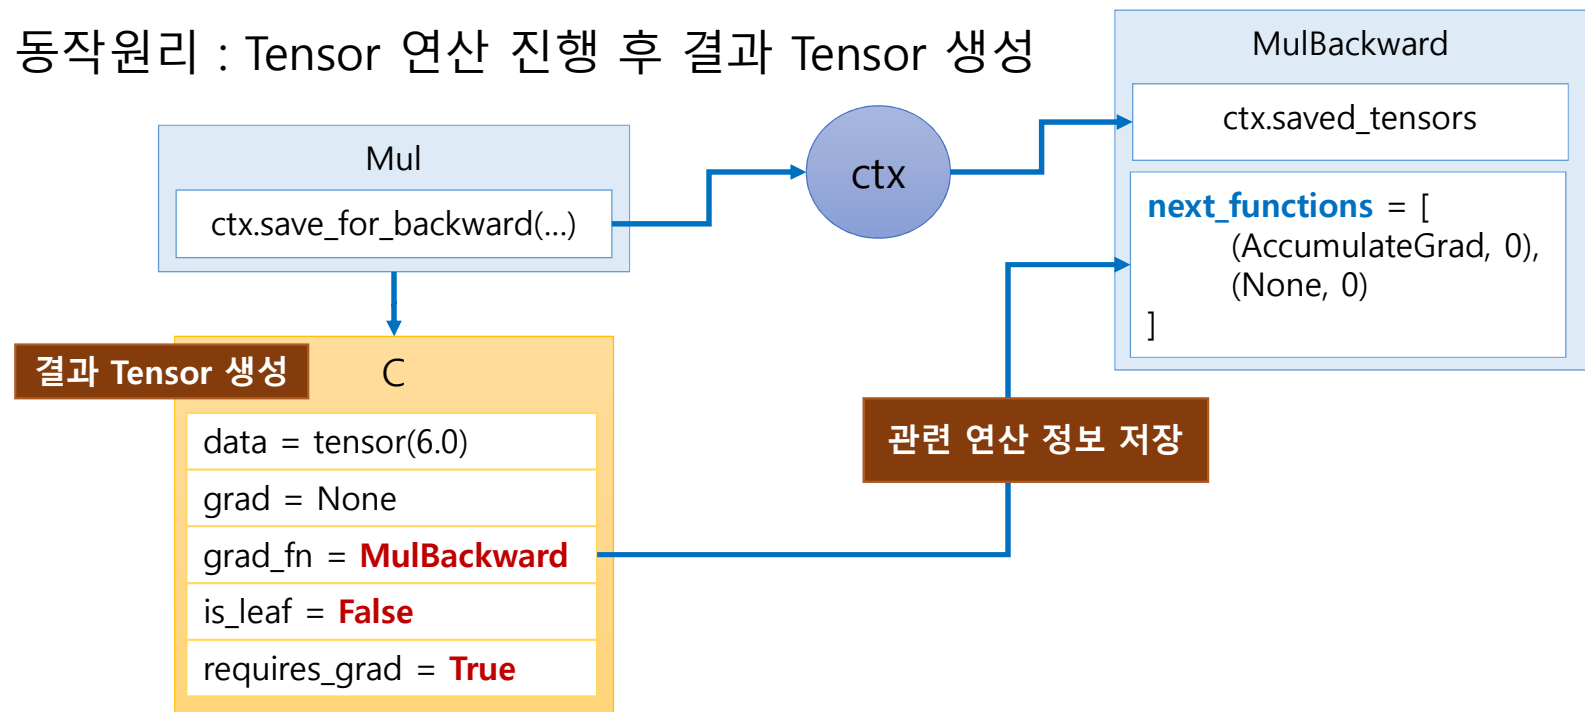




# ABOUT AUTOGRAD

## ◆ torch.autograd

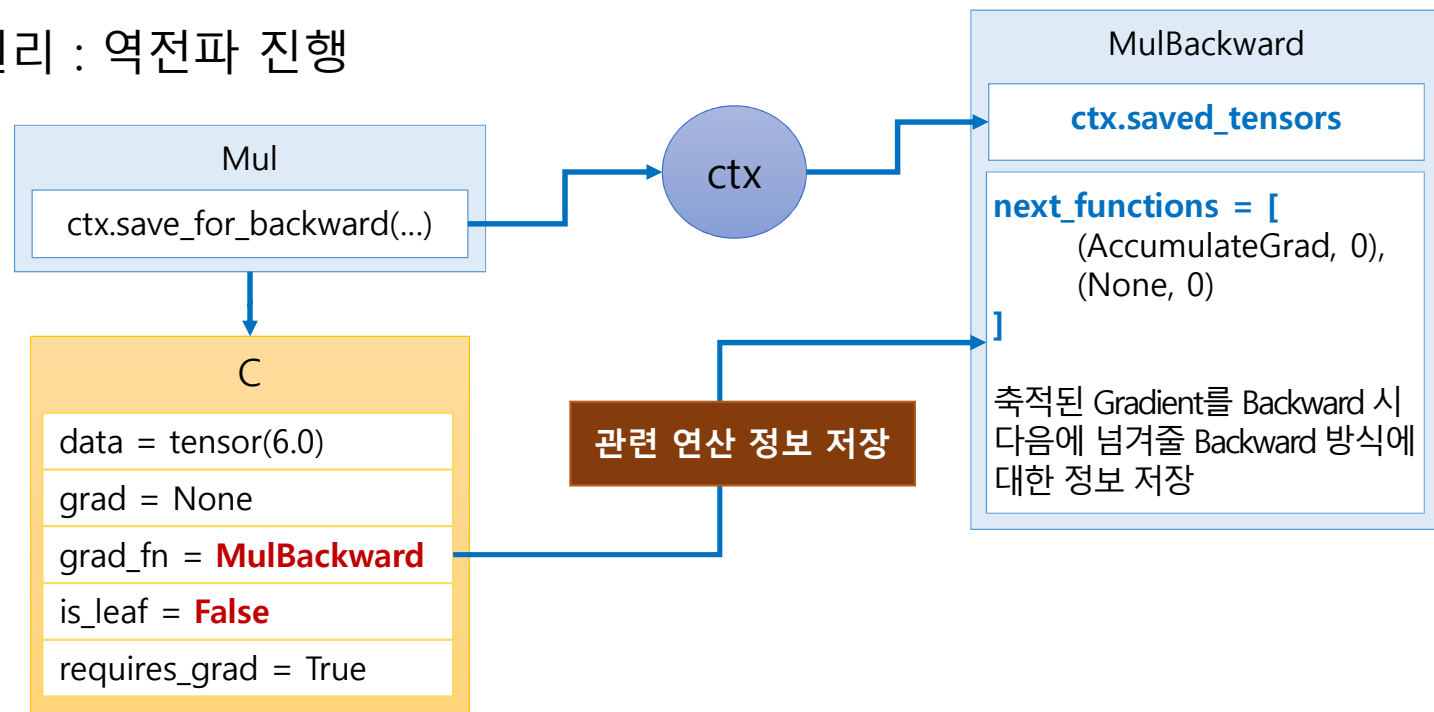
❖ 동작원리 : Tensor 연산 진행 후 결과 Tensor 생성



# ABOUT AUTOGRAD

## ◆ torch.autograd

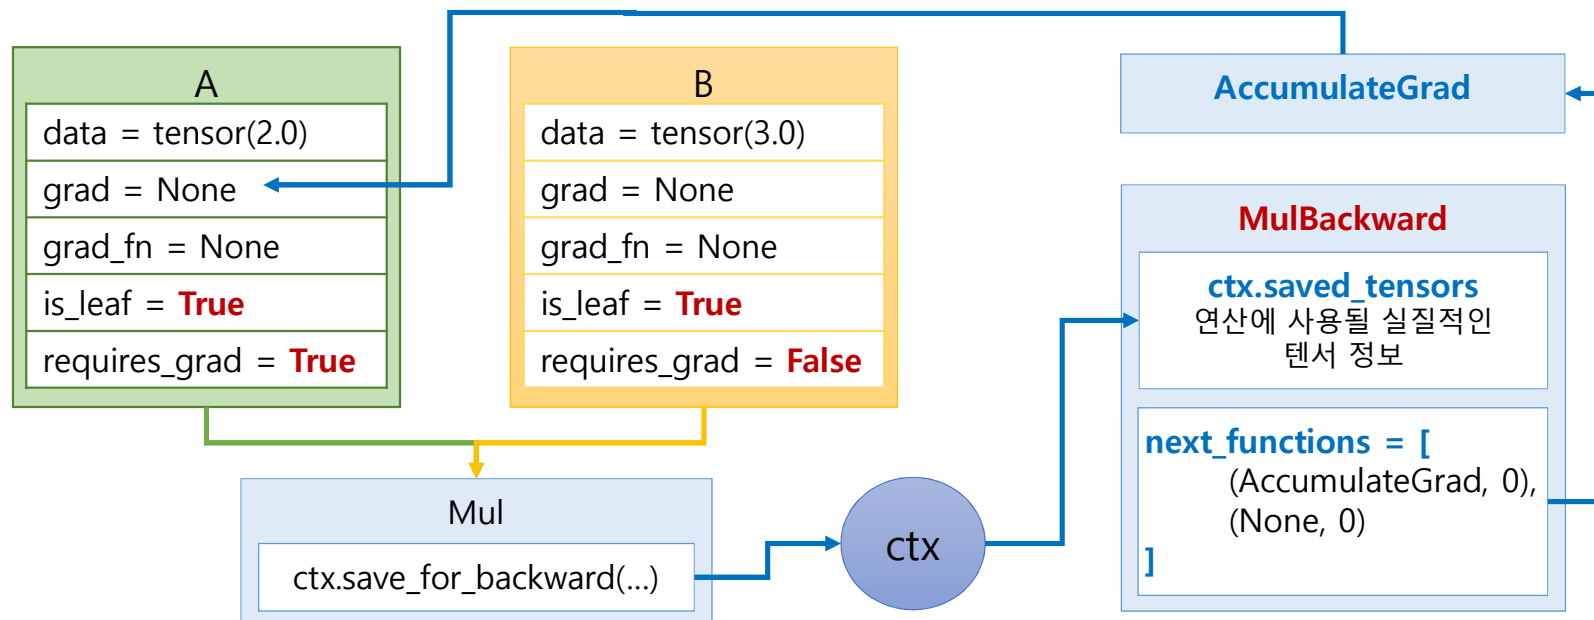
❖ 동작원리 : 역전파 진행



# ABOUT AUTOGRAD

## ◆ torch.autograd

❖ 동작원리 : 역전파 진행



# ABOUT AUTOGRAD

---

## ◆ torch.autograd

### ❖ 데이터 업데이트 조건

- `.requires_grad = True`
- `.is_leaf = True`

# ABOUT AUTOGRAD

---

## ◆ torch.autograd

❖ 자동미분 설정 → `requires_grad = True` 설정된 Tensor 업데이트 진행됨

```
# 역전파 진행으로, 가중치/절편 업데이트
```

```
loss.backward()
```

```
for name, param in linear_model.named_parameters():  
    print(name, param)
```

# ABOUT AUTOGRAD

---

## ◆ torch.autograd

❖ 자동미분 해제 → `torch.no_grad()` , `detach()`

```
with torch.no_grad():  
    z = torch.matmul(x, w)+b  
print(z.requires_grad)
```

```
z = torch.matmul(x, w)+b  
z_det = z.detach()  
print(z_det.requires_grad)
```

# ABOUT AUTOGRAD

## ◆ 손실함수(Loss Function)

### ❖ torch.nn.functional

`l1_loss`

`mse_loss`

`margin_ranking_loss`

`multilabel_margin_loss`

`multilabel_soft_margin_loss`

### ❖ torch.nn.Loss Class

`nn.L1Loss`

`nn.MSELoss`

`nn.CrossEntropyLoss`

`nn.CTCLoss`

`nn.NLLLoss`

`nn.PoissonNLLLoss`

# ABOUT AUTOGRAD

## ◆ 손실함수(Loss Function)

❖ `torch.nn.functional` / `torch.nn`

유형		손실함수	
회귀		<code>torch.nn.MSELoss</code>	평균 제곱 오차(Mean Squared Error)
		<code>torch.nn.L1Loss</code>	평균 절대 오차(Mean Absolute Error)
교차 엔트로피	다중	<code>torch.nn.CrossEntropyLoss</code>	교차 엔트로피 손실(Cross Entropy Loss)
	이진	<code>torch.nn.BCELoss</code>	이진 교차 엔트로피 손실(Binary Cross Entropy Loss)



# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화 클래스

### ❖ torch.optim 클래스

- $w$ ,  $b$  업데이트 처리 클래스
- 필수 매개변수 : 모델 파라미터(`model.parameters()`)와 학습률(`lr`)

<code>torch.optim.SGD</code>	가장 기본적인 최적화 알고리즘 각각의 파라미터에 대해 학습률(learning rate) 곱한 값 사용 가중치 업데이트
<code>torch.optim.Adam</code>	학습률을 각 파라미터마다 적응적으로 조절하는 최적화 알고리즘 현재 그래디언트와 이전 그래디언트의 지수 가중 평균 이용 가중치 업데이트
<code>torch.optim.RMSprop</code>	그래디언트의 제곱값의 이동 평균을 이용하여 학습률 조절하는 최적화 알고리즘 Adam과 유사한 방식으로 학습률 조절
<code>torch.optim.Adagrad</code>	각 파라미터에 대한 학습률을 조절하는 최적화 알고리즘 이전 그래디언트 제곱의 누적 값 사용하여 학습률 조절

# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화 클래스

### ❖ Model Parameters

#### ▪ 층별 $w$ , $b$ 텐서들로 역전파 시 업데이트

<code>model .parameters()</code>	<ul style="list-style-type: none"><li>• 모델의 학습 가능한 파라미터들 반환</li><li>• 모델의 모든 레이어 및 모듈에서 정의된 파라미터들 포함</li><li>• 모델이 학습 중에 업데이트되는 값들</li><li>• 최적화 알고리즘 통해 업데이트되는 대상</li><li>• 학습 데이터와 손실 함수를 통해 계산된 그라디언트를 사용하여 업데이트</li></ul>
<code>model .named_parameters()</code>	<ul style="list-style-type: none"><li>• <code>parameters()</code>와 동일 기능</li><li>• 파라미터 이름과 값을 전달</li></ul>

# ABOUT AUTOGRAD

## ◆ 가중치/절편 최적화

### ❖ torch.optim 클래스

```
# 가중치/절편 최적화 방법 설정
from torch.optim import Adam

# W, b 업데이트 위한 모델 파라미터 설정
optimizer = Adam( linear_model.parameters(), lr=LR )
```

Adadelta

Adagrad

Adam

AdamW

SparseAdam

# ABOUT AUTOGRAD

---

## ◆ 가중치/절편 최적화

### ❖ torch.optim 클래스

```
# 가중치 기울기 0 초기화
optimizer.zero_grad()

# 학습 진행
pre_y = linear_model(x)

# 손실 계산
loss = nn.MSELoss()(pre_y, y.reshape(-1,1))

# 역전파 진행
loss.backward()

# 가중치/절편 업데이트
optimizer.step()
```

# MODEL TRAIN & TEST

# MODEL TRAIN & TEST

## ◆ 학습 과정

### ❖ 주제 및 목표 선정

데이터셋  
수 집

데이터 분석  
학습방법  
학습종류  
구현방법

학습 방법 설정  
에포크/배치/LR

모델 및 최적화  
인스턴스 준비

학습진행

학습평가

# MODEL TRAIN & TEST

## ◆ 학습

### ❖ 데이터 분석

- 피쳐와 타겟 선정
- 학습 방법 선정
  - 지도 학습 : 문제/속성/피쳐 + 정답/라벨/타겟
  - 비지도학습 : 문제
  - 강화 학습 : 문제 + 피드백(상과 벌)
- 학습 종류 선정 : 회귀 / 분류
  - 회귀(Regression) : 수치값 예측
  - 분류(Classification) : 데이터 그룹/묶음 나누기

# MODEL TRAIN & TEST

## ◆ 학습

### ❖ 데이터 분석

#### ▪ 구현 방법 선정





# MODEL TRAIN & TEST

---

## ◆ 학습

### ❖ 데이터셋 분리

- 학습용 데이터셋 : 학습 전용 데이터 셋
- 테스트용 데이터셋 : 학습 후 성능평가 위한 데이터 셋
- 검증용 데이터셋 : 모델 성능 개선 체크용 데이터 셋


# MODEL TRAIN & TEST

## ◆ 학습

### ❖ 학습용 데이터셋 분리

#### ▪ 딥러닝 대량 데이터 학습 시간/비용 많이 소요 부분 대책

- **에포크(epochs)** : 처음부터 끝까지 학습하는 횟수
- **배치크기(batch size)** : 전체 데이터를 작은 단위로 나눈 크기  
2의 제곱수 크기
- **이터레이션(iteration)** : 에포크, 배치크기로 계산한 반복 횟수  
W,b 업데이트 횟수
- 예) 100개 데이터, 배치크기 20개, 에포크 10번



# MODEL TRAIN & TEST

---

## ◆ 학습

### ❖ 학습용 데이터 준비

```
# DataFrame ==> Feature 추출
X = bostonDF.iloc[:, :13].values
Y = bostonDF['medv'].values

print(f'X : {type(X)}, {X.shape}\nY : {type(Y)}, {Y.shape}')
```

# MODEL TRAIN & TEST

---

## ◆ 학습

### ❖ 학습 설정

```
# 학습 횟수 및 한번에 학습할 데이터 크기 설정  
EPOCHS = 500  
BATCH_SIZE = 100  
LR = 0.001
```

# MODEL TRAIN & TEST

---

## ◆ 학습

### ❖ 학습 설정

```
# 모델 인스턴스 생성
linear_model = nn.Sequential(nn.Linear(13, 10),
                              nn.ReLU(),
                              nn.Linear(10, 1))
```

# MODEL TRAIN & TEST

---

## ◆ 학습

### ❖ 학습 설정

```
# 가중치/절편 최적화 방법 설정
from torch.optim import Adam

optimizer = Adam(linear_model.parameters(), lr=LR)
```

# MODEL TRAIN & TEST

## ◆ 학습

### ❖ 학습 설정 - 모델 동작모드 설정

유형	설정 함수	
학 습 모 드	model.train()	<p>* 모델 학습 전 호출 → 훈련 데이터에 대해 학습 시작할 준비</p> <ul style="list-style-type: none"><li>- 정규화(regularization) 기법들 동작 설정</li><li>- 모델 파라미터 업데이트를 위해 역전파(backpropagation) 수행</li><li>- 그래디언트 계산 수행</li><li>- 최적화(optimizer) 알고리즘에 따라 모델 파라미터 업데이트</li></ul>

# MODEL TRAIN & TEST

## ◆ 학습

### ❖ 학습 설정 - 모델 동작모드 설정

유형	설정 함수	
평가 모드	model.eval()	<ul style="list-style-type: none"><li>* 모델 평가/추론 모드 전환</li><li>* 테스트 데이터나 검증 데이터 사용하여 모델 평가할 때 사용</li><li>- 정규화(regularization) 기법들 비활성화 설정</li><li>- 드롭아웃 비활성화, 배치 정규화 이동 평균/이동 분산 업데이트 않됨</li><li>- 역전파 비활성화로 모델 파라미터 업데이트 않됨</li></ul>



# MODEL TRAIN & TEST

---

## ◆ 학습

### ❖ 학습 진행

```
for epoch in range(EPOCHS):  
    for i in range(len(X)//BATCH_SIZE):  
        start = i*BATCH_SIZE  
        end = start + BATCH_SIZE  
  
        # ndarray ==> tensor변환  
        x = torch.FloatTensor(X[start:end])  
        y = torch.FloatTensor(Y[start:end])
```

# MODEL TRAIN & TEST

## ◆ 학습

### ❖ 학습 진행

```
# 가중치 기울기 0 초기화
optimizer.zero_grad()

# 학습 진행
pre_y = linear_model(x)

# 손실 계산
loss = nn.MSELoss()(pre_y, y.reshape(-1,1))

# 역전파 진행
loss.backward()

# 가중치/절편 업데이트
optimizer.step()
```

# MODEL TRAIN & TEST

---

## ◆ 학습

### ❖ 모델 평가

```
# 모델 성능 평가
pre = linear_model(torch.FloatTensor(X[0, :13]))

pre, Y[0]
```